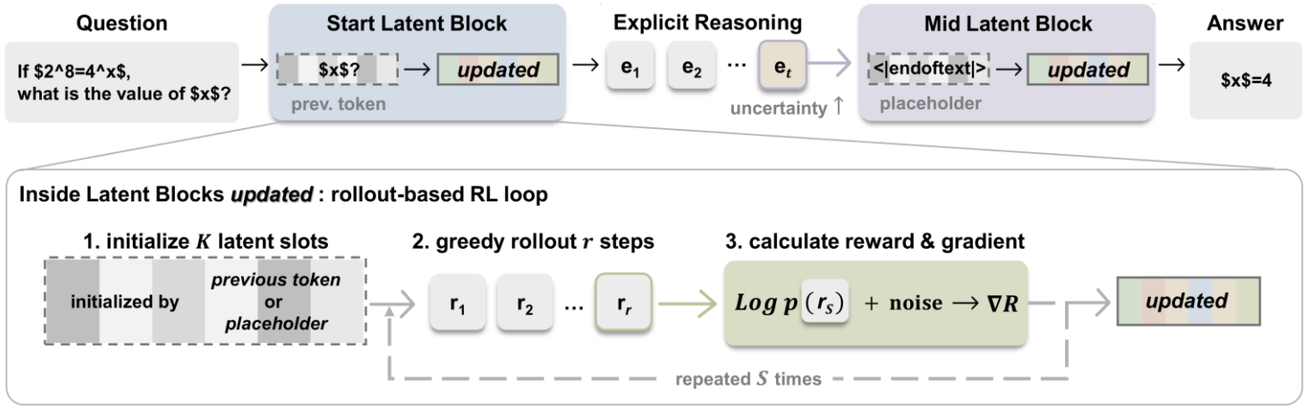
PROJECT 05 · Latent Block · test-time 추론 최적화

# 생성 중 잠재 벡터를 최적화해 추론 성능 개선

Adaptive Latent Block Insertion via Online Reward Optimization · EMNLP 2026 Main 게재 확정 · 2저자




불확실성(uncertainty)이 높아지는 지점에 Mid Latent Block을 삽입하고, 짧은 rollout r회의 confidence를 보상으로 latent 벡터를 S회 갱신합니다. 학습 없이 추론 시점에만 동작합니다.

| Method | GSM8K | MATH500 | AIME2024 | AIME2025 | ASDivAug | Mean |
|---|---|---|---|---|---|---|
| | B@8 / A@8 | B@8 / A@8 | B@8 / A@8 | B@8 / A@8 | B@8 / A@8 | B@8 / A@8 |
| Zero-shot CoT | 95.91 / 91.76 | 85.60 / 71.47 | 16.67 / 10.00 | 16.67 / 8.75 | 95.09 / 93.12 | 61.99 / 55.02 |
| SoftCoT | 95.15 / 91.04 | **91.60** / 82.17 | 40.00 / 22.08 | 26.67 / 18.75 | 96.92 / 93.99 | 70.07 / 61.61 |
| LTPO | 95.07 / 92.29 | 91.00 / 83.25 | 33.33 / 21.67 | 26.67 / 19.17 | 96.63 / 83.77 | 68.54 / 60.03 |
| Ours (w/o mid) | 95.83 / 93.26 | 89.68 / 81.09 | 36.67 / 22.92 | **30.00** / 18.75 | 96.54 / 93.70 | 69.74 / 61.94 |
| **Ours** | **96.91** / 91.51 | 91.02 / 81.28 | **46.67** / 25.00 | **30.00** / 19.17 | **96.98** / 92.72 | **72.32** / 61.94 |

Table. Qwen3-14B 결과. B@8 = Best-of-8, A@8 = Avg-of-8 정확도(%). SoftCoT는 projection module을 직접 학습해 비교.

**문제**

LLM은 풀이 중간에 확신이 떨어지는 구간에서 오답으로 흐르지만, 이를 학습으로 고치려면 모델 재훈련이 필요합니다. 추론 시점에만 개입해 성능을 올리는 방법이 필요했습니다.

**역할**

비교 기법(LTPO·SoftCoT)을 직접 훈련·실험하고 제안 방법과 같은 조건에서 비교하는 작업을 맡았습니다.

**해결**

- ✓ 제안 방법: 토큰별 불확실성이 이어지는 구간을 감지해 Mid Latent Block을 삽입하고, 짧은 rollout의 confidence를 보상으로 latent 벡터를 문제별로 최적화 (training-free)
- ✓ LTPO 실험: 생성 시작점에서만 latent를 최적화하는 방식과 비교해 중간 삽입의 효과 검증
- ✓ SoftCoT 훈련: 보조 모델의 latent를 LLM에 연결하는 projection module을 Qwen3·Ministral에서 학습해 학습 기반 방법과도 같은 조건에서 비교

**성과**

벤치마크 5종 Mean B@8 개선 · EMNLP 2026 Main Accepted

**관찰·해석**

latent 추론은 사고 과정을 explicit한 텍스트가 아닌 연속 벡터에 담아 토큰 생성 비용을 줄이고, 여기에 test-time 최적화를 더하면 재훈련 없이도 정확도를 훈련 방법론 이상으로 높일 수 있음을 확인했습니다.