PROJECT 07 · FineWeb-Reasoning · 추론 중심 사전학습 데이터

보상 함수 설계로 base 모델을 SFT 없이 GRPO 학습

추론 품질 채점 프롬프트 검증 · base 모델 GRPO · reward hacking 유형별 감점 보상함수 설계

GSM8K 12.1→43.0
LogiQA 14.8→37.2

SFT 없이 base 모델 RL 성공 · 동급 일반 코퍼스 모델 초과

GSM8K 12.1→43.0, LogiQA 14.8→37.2로 동급 일반 코퍼스 모델을 넘고 SmolLM2 이상
고품질 추론 문서로 사전학습한 자체 base 모델에 cold start(SFT) 없이 GRPO만 적용

학습 파이프라인 · 4단계

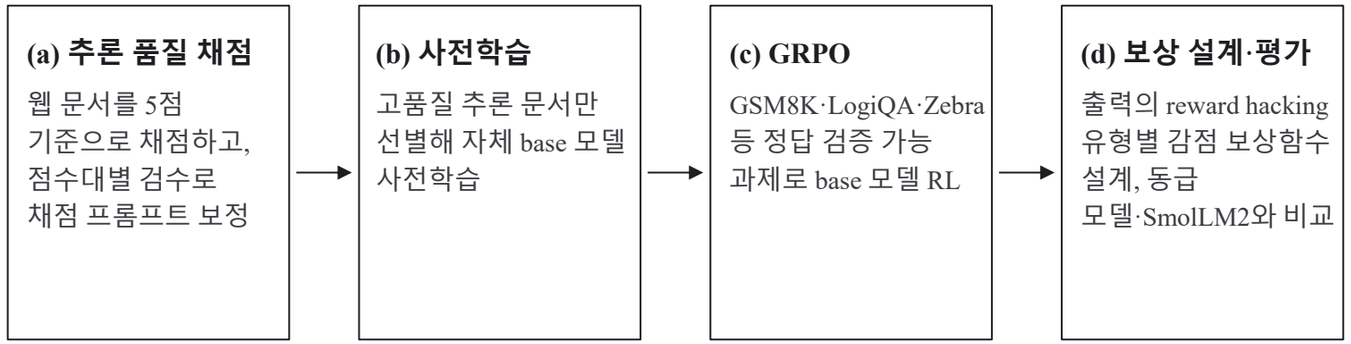


Figure. 추론 데이터 선별부터 base 모델 GRPO까지의 학습 파이프라인.

문제

5점 추론 채점 기준이 실제 품질과 어긋나는 사례가 있었고, 형식·정답만 보는 보상으로 base 모델을 GRPO하면 객관식에서 보상만 오르고 출력이 무너졌습니다.

역할

추론 품질 평가 프롬프트 검증과, 그 데이터로 사전학습한 base 모델의 GRPO를 맡았습니다.

해결

- ✓ 점수대별 문서를 직접 검수해 채점과 실제 추론 품질이 어긋나는 사례를 찾아 추론 품질 평가 프롬프트에 반영
- ✓ 출력을 읽어 선택지 나열, think 비우기, 단서 베끼기 등 편법 유형을 나누고 유형별로 감점하는 보상함수 설계
- ✓ Zebra는 같은 그리드 문항이 학습·평가에 섞이지 않게 재분할
- ✓ cold start(짧은 SFT)보다 보상 설계만으로 푼 쪽이 더 높은 성능

성과

GSM8K 12.1→43.0 (동급 일반 코퍼스 모델 초과)
LogiQA 14.8→37.2 (SmolLM2 이상)

관찰·해석

보상함수는 점수가 아니라 출력을 실제로 읽어야 검증됩니다. 보상만 오르는 학습은 편법을 배우는 reward hacking일 수 있습니다. 실제 출력에서 편법 유형을 찾아 보상에 반영했고, 이 경험이 이후 루브릭 RL에서 보상 분포와 파싱을 점검하는 기준이 됐습니다.