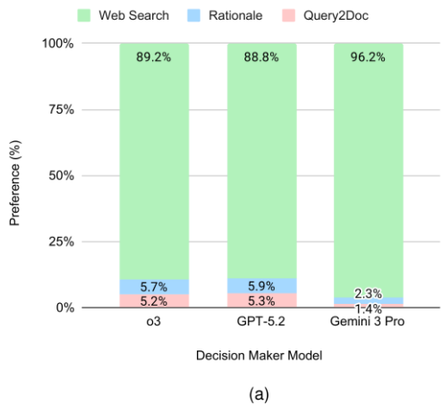
PROJECT 02 · 최신 모델로 단계별 성능을 분해해 자기 편향을 찾아 EM 0.84 → 0.87

Ensemble Multi-Retrieval Methodologies with Reasoning Model Decision in Multi-Step Biomedical QA [논문 PDF]

Database (Oxford Univ. Press, SCIE) 게재 · 공동1저자 · 챌린지 뒤 Gemini 3 Pro · GPT-5.2 · o3로 재실험



(a)

96.2%

자기 후보 선택 편향

Gemini 3 Pro가 판단까지 맡으면 자신이 만든 Web Search 후보를 최대 96.2% EM 0.84~0.85

0.87

EM · 생성·판단 모델 분리

생성 Gemini 3 Pro + 판단 GPT-5.2. Web 후보 의존이 90.9% → 77.5%로 낮아지며 비교 구성 중 최고

Query2Doc	Rationale	Web Search	Decision Maker	EM Score
GPT-5.2	GPT-5.2	Gemini 3 Pro	o3	0.86
			GPT-5.2	0.86
			Gemini 3 Pro	0.85
Gemini 3 Pro	Gemini 3 Pro	Gemini 3 Pro	GPT-5.2	0.87
			Gemini 3 Pro	0.84

Figure(왼쪽 위). Decision Maker 모델별 세 후보(Web Search·Rationale·Query2Doc) 선택 비율. Table. 생성 모델과 Decision Maker 조합별 테스트 EM(1만 문항). 생성 모델이 같아도 Decision Maker를 GPT-5.2로 바꾸면 0.84 → 0.87.

문제

챌린지 뒤 각 단계에 GPT-5.2·Gemini 3 Pro를 적용했습니다. Gemini 3 Pro는 단독 경로에서 가장 강했지만 판단까지 맡기면 자기 후보에 치우쳐 전체 EM이 0.84~0.85에 머물렀습니다. 문항마다 필요한 검색 방식과 추론 깊이도 달라 세 경로를 모두 돌리는 비용이 컸습니다.

역할

모델 조합·retrieval 단계별 기여 분석, 편향 진단과 구조 개선 실험을 맡았습니다.

해결

- ✓ **생성·판단 분리:** 생성은 Gemini 3 Pro, 판단은 GPT-5.2로 나눠 자기 편향을 줄이고 EM 0.87 달성
- ✓ **Sparse vs Dense:** Qwen3-embedding-8B 밀집 색인과 EM 차이 ±0.02 이내, sparse가 42.5% 빠르고 VRAM 140GB 불필요 → sparse 유지
- ✓ **라우팅 에이전트:** 문항별 reasoning effort와 RAG 방법·순서를 정하는 에이전트를 소규모 실험, 성능 향상 확인 (전체 검증은 API 비용으로 보류)

성과

EM 0.84 → 0.87, 비교 구성 중 최고

Database (Oxford Univ. Press, SCIE) 게재 · 공동 1저자

관찰·해석

개별 모델의 성능과 시스템 전체의 성능은 다릅니다. 결과가 기대에 못 미치면 검색·생성·판단 단계로 나눠 기여를 재고, 판단 모델의 자기 편향을 확인한 뒤 구조를 바꿉니다.