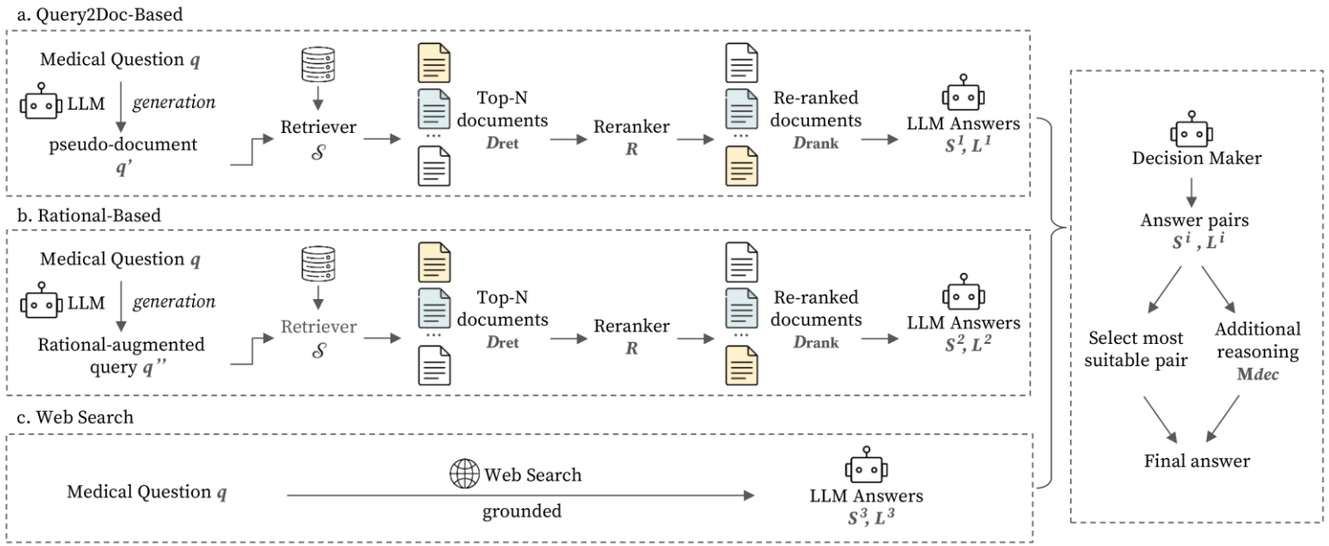
PROJECT 01 · 의료 multi-hop QA 챌린지

Agentic RAG로 의료 multi-hop QA 챌린지 1위

BioCreative IX shared task · IJCAI 2025 Workshop · 공동 1저자



세 retrieval 경로(a. Query2Doc, b. Rationale, c. Web Search)가 각각 답 후보를 만들고, Decision Maker가 최선의 후보를 고르거나 적합한 후보가 없으면 직접 추론합니다.

1위

BioCreative IX 리더보드

공식 테스트 EM 0.84

3종

retrieval 구축·비교

Query2Doc · Rationale · Web

문제

여러 근거를 거쳐야 답이 나오는 의료 질문은 한 가지 검색 방식으로는 답 후보를 놓칩니다. 위키 검색과 최신 웹 정보 검색 및 추론이 각각 필요한 문항이 섞여 있었습니다.

역할

서로 성격이 다른 세 retrieval 방법론의 구축과 비교 실험을 맡았습니다.

해결

- ✓ **Query2Doc:** LLM이 질문에 대한 가상 문서를 먼저 쓰고, 그 문서로 위키 근거를 검색해 답 후보 생성
- ✓ **Rationale:** 추론 모델이 단계별로 푼 답변 자체를 질의로 써서 근거 문서를 다시 찾아 검증
- ✓ **Web Search:** Claude·GPT·Gemini 검색 결합 모델을 비교해 가장 정확한 Gemini + Google Search 조합 선정
- ✓ 세 후보의 판단을 종합하여 Decision Agent가 최종 판단을 내리는 구조로 완성

성과

공식 테스트 EM 0.84로 1위, IJCAI shared task 논문 공동 1저자

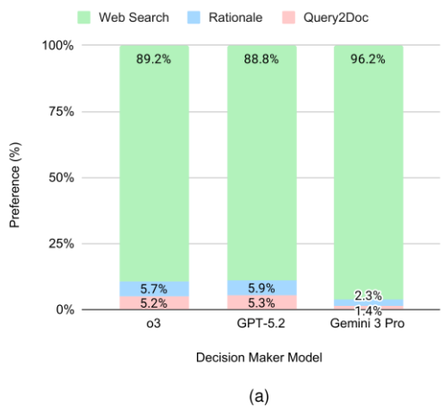
관찰·해석

검색 방식마다 잘 풀리는 질문이 달랐습니다. 후보는 여러 갈래로 넓게 만들고 판단은 따로 맡기는 구조가 단일 파이프라인보다 안정적이었고, 여러 지식원과 추론이 함께 쓰이는 문제에도 일반화할 수 있습니다.

PROJECT 01 · MedHopQA 확장 연구

구성 단계별·모델별 성능을 분해해 판단 편향을 찾아 EM 0.84 → 0.87

Database (Oxford University Press, SCIE) 게재 · 공동 1저자



(a)

96.2%

자기 후보 선택 편향

Gemini 3 Pro가 판단까지 맡으면 자신이 만든 웹 검색 후보를 96.2% 선택
(o3 89.2%, GPT-5.2 88.8%)

0.87

EM · 비교 구성 중 최고

생성 Gemini 3 Pro + 판단 GPT-5.2로 분리

Query2Doc	Rationale	Web Search	Decision Maker	EM Score
GPT-5.2	GPT-5.2	Gemini 3 Pro	o3	0.86
			GPT-5.2	0.86
			Gemini 3 Pro	0.85
Gemini 3 Pro	Gemini 3 Pro	Gemini 3 Pro	GPT-5.2	0.87
			Gemini 3 Pro	0.84

Figure(왼쪽 위). Decision Maker 모델(o3·GPT-5.2·Gemini 3 Pro)별로 세 retrieval 후보(Web Search·Rationale·Query2Doc) 중 무엇을 선택했는지의 비율.
Table. 각 retrieval 경로의 생성 모델과 Decision Maker 모델 조합별 EM. 생성 모델이 같아도 Decision Maker를 GPT-5.2로 바꾸면 0.84 → 0.87.

문제

챌린지 이후 retrieval 경로와 판단 단계에 GPT-5.2와 Gemini 3 Pro를 적용해 성능을 비교했습니다. 후보 생성에 강한 Gemini 3 Pro가 판단까지 맡으면 EM은 0.84에 그쳤습니다.
또 질문마다 필요한 검색 방식과 추론 깊이가 달라, 모든 질문에 세 경로를 다 돌리는 것은 비용 낭비였습니다.

역할

모델 조합·retrieval 단계별 기여 분석, 편향 진단과 구조 개선 실험을 맡았습니다.

해결

- ✓ 단계별로 모델을 바꿔 EM을 비교하고 판단 모델의 자기 편향을 확인해, 생성·판단 분리로 EM 0.87을 달성했습니다.
- ✓ 질문마다 reasoning effort와 RAG 방법·순서를 정하는 라우팅 에이전트를 설계해 소규모로 실험하여 성능 향상을 확인했습니다. (전체 검증은 API 비용으로 보류).

성과

EM 0.84 → 0.87, 비교 구성 중 최고 · SCIE 저널 Database 게재

관찰·해석

개별 모델의 성능과 시스템 전체의 성능은 다릅니다. 기대에 못 미치는 결과가 나오면 검색·생성·판단 단계를 나눠 결과를 보고, 원인을 확인한 뒤 구조를 바꿉니다.