PROJECT 01 · Agentic RAG로 의료 multi-hop QA 챌린지 1위, 공식 테스트 EM 0.84

DMIS Lab at MedHopQA-2025: Ensemble Multi-Retrieval Methodologies with Reasoning Language Model Decision [논문 PDF]

BioCreative IX MedHopQA track (13팀 참가) · IJCAI 2025 BC9 Workshop 논문 · 공동 1저자

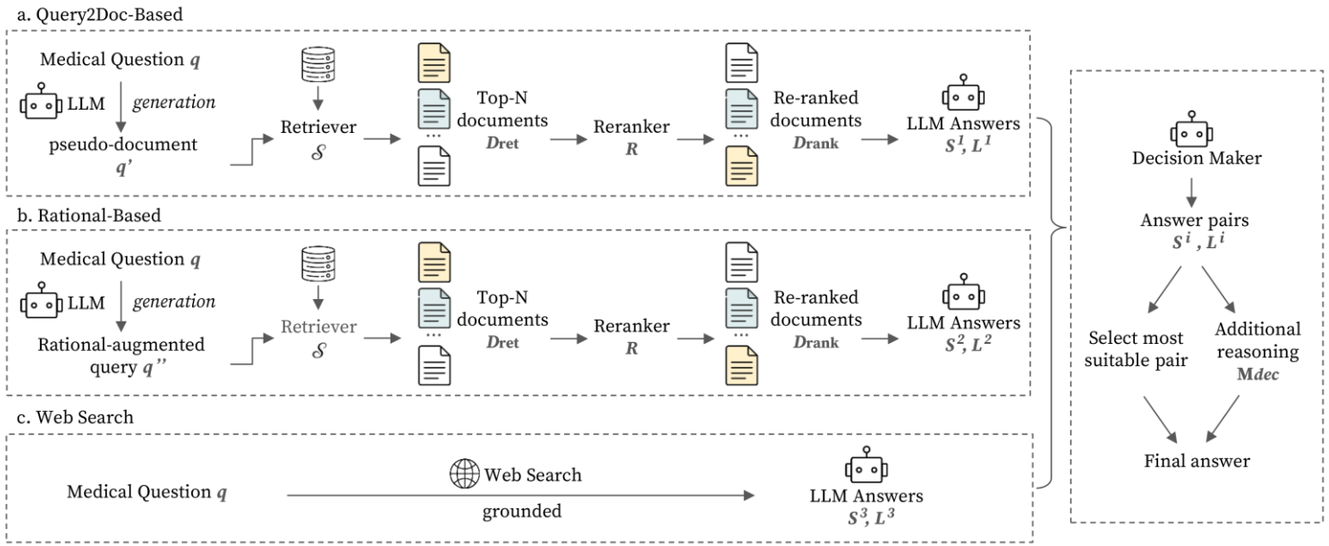


Figure. 세 retrieval 경로가 각각 답 후보(단답·근거)를 만들고, Decision Maker(o3)가 최선의 후보를 고르거나 적합한 후보가 없으면 직접 추론합니다. Query2Doc·Rationale은 위키 sparse 검색 + MedCPT 재정렬, Web Search는 Gemini 2.5 Pro + Google Search를 사용합니다.

1위

BioCreative IX 리더보드

13팀 중 1위 · 테스트 EM 0.84

0.84

테스트 EM · 최종 구성

검색 3경로 + o3 판단 모델
공식 리더보드

문제

MedHopQA는 희귀질환·유전자·화합물을 여러 위키 문서에 걸쳐 추론하는 1만 문항입니다. 검색 없는 GPT-4o는 dev EM 0.60에 그쳤고, 문항마다 맞는 검색 방식이 달랐습니다.

역할

서로 성격이 다른 세 retrieval 방법론의 구축과 비교 실험을 맡았습니다.

해결

- ✓ **Query2Doc:** GPT-4o가 쓴 가상 문서로 위키 sparse 검색 1,000건 → MedCPT 재정렬 200건, GPT-4o가 답 후보 생성
- ✓ **Rationale:** o3가 추론 과정을 담은 질의를 만들고 위키 검색·재정렬 뒤 GPT-4o가 답 후보 생성
- ✓ **Web Search:** Gemini 2.5 Pro + Google Search로 웹 검색 기반 근거 후보 생성
- ✓ **Decision Maker:** o3가 세 후보를 비교해 선택, 적합한 후보가 없으면 직접 답변

성과

공식 테스트 EM 0.84 1위 · IJCAI BC9 Workshop 논문 공동 1저자

관찰·해석

dev 셋에서 검색 없는 GPT-4o가 EM 0.60, 검색 추가로 0.82, 세 검색 경로 + 판단 모델 프레임워크로 0.87까지 상승했습니다. 같은 구성으로 공식 테스트셋 EM 0.84를 기록해 리더보드 1위에 올랐습니다.