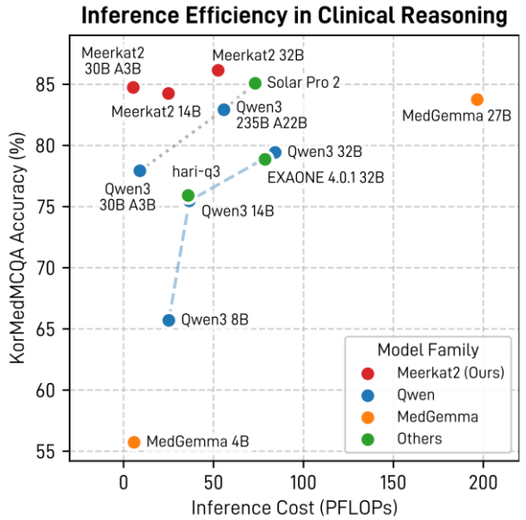
PROJECT 04 · 한·영 의료 추론 LLM Meerkat2: Base 모델 대비 의료 질의응답 성능 개선

Meerkat2: Bridging Global Reasoning and Local Knowledge for Efficient Medical AI [논문 PDF]

Qwen3 14B·32B·30B-A3B 기반 학습 · EMNLP 2026 Main 게재 확정 · 2저자

추론 비용 대비 KorMedMCQA 정확도



x축 총 추론 비용(PFLOPs) · y축 KorMedMCQA 정확도(%)

Model	Diagnosis Arena	MediQ	HealthBench Hard	Avg.
Qwen3-14B	8.9	51.0	8.9	22.9
Meerkat2-14B	**12.8**	**60.3**	**9.1**	**27.4**
Qwen3-30B-A3B	12.0	55.5	8.3	25.2
Meerkat2-30B-A3B	**12.4**	**57.2**	**9.3**	**26.3**
Qwen3-32B	13.6	**54.4**	9.1	**25.7**
Meerkat2-32B	**14.6**	51.2	**11.2**	**25.7**

Table. 실제 진료 환경과 유사한 벤치마크 3종

학습 데이터 837K, 세 가지 원칙

01 교사 모델의 풀이 과정 증류

MedQA·KorMedMCQA·MedBooks 문제의 풀이 과정과 답을 교사 모델로 생성하고, 정답을 맞힌 사례를 선별해 학습에 활용

02 법령 지식은 원문에서 합성

한국 의료법 원문에서 문제·해설 QA를 직접 생성. 법령 정확도(LF-Eval) 98.7, 단순 distillation은 79.0

03 장황함 분리 증류(VDD)

긴 teacher 모델 답변에는 "길게 답하라" 지시를 붙여 학습. 정확도 유지하며 생성 토큰 54% 절감

문제

공개 의료 LLM은 영어·미국 진료 기준에 맞춰져 한국 의료법·제도 지식이 약합니다. 또 긴 사고과정을 그대로 증류하면 student 모델이 teacher 모델의 장황한 답변 스타일까지 물려받습니다.

역할

한국 의료법 원문을 기반으로 한 합성 QA를 LF-Eval·수동 검수로 검증하고, HealthBench 등 실전 진료형 벤치마크 3종 평가를 맡았습니다.

해결

✓ 추론은 강한 교사 모델에게서 증류하고, 틀리면 안 되는 법령 지식은 원문에서 QA를 직접 만들어 학습 데이터를 분리

✓ 장황한 답변은 지시문에 귀속시켜(VDD) 추론력만 물려받고 기본 답변 길이는 짧게 유지

성과

✓ **KorMedMCQA에서 14B·32B·30B-A3B 모두 동일 규모 Qwen3 대비 정확도 향상**

✓ **실전 진료형 벤치마크 3종 평균 최대 +4.5점** (14B, 22.9→27.4)

관찰·해석

지식의 종류에 따라 데이터 만드는 법이 달라야 합니다. 추론은 교사에게서 배우되, 사실은 원문에서 직접 만들어 검증합니다. 교사 모델은 사고 과정은 잘 보여주지만 한국 법령·제도 같은 사실은 모르거나 틀리게 답하는데, 이를 그대로 증류하면 오류까지 학습하기 때문입니다.

PROJECT 04 · Meerkat2 후속 연구 · 루브릭 보상 RL

Meerkat2 후속 연구: 루브릭 기반 SFT·RL로 HealthBench 9.0점 향상

Meerkat2 14B·32B를 서술형 의료 상담(HealthBench)에 맞게 추가 학습 · 논문 후속 연구

Model	Training	HealthBench	vs. 학습 전
Meerkat2-14B	–	44.9	—
Meerkat2-14B	**Rubric RL**	**51.2**	**+6.3**
Meerkat2-32B	–	46.3	—
Meerkat2-32B	SFT	51.0	+4.7
Meerkat2-32B	**SFT + Rubric RL**	**55.3**	**+9.0**

Table. HealthBench score. 서술형 의료 QA 5,000문항을 의사 작성 루브릭으로 채점. 32B에서 루브릭 RL은 SFT 단독(+4.7) 대비 개선 폭을 약 2배(+9.0)로 확대.

Results

두 모델 모두 학습 전 Meerkat2를 넘음

14B는 44.9→51.2(+6.3), 32B는 46.3→55.3(+9.0)으로 모델 크기와 무관하게 루브릭 RL이 서술형 답변의 질을 끌어올렸습니다.

SFT와 RL이 단계별로 성능을 향상시킴

32B에서 선별한 데이터로 SFT를 하면 46.3→51.0(+4.7), 그 위에 루브릭 RL을 더하면 55.3(+4.3)으로 두 단계가 비슷한 폭으로 기여해 성능을 9.0점 상승시켰습니다.

문제

객관식은 잘 풀어도 서술형 의료 QA(HealthBench 등)는 부족했습니다. 루브릭 점수를 보상으로 RL을 돌리자, 수십 개 항목을 한 번에 채점하는 기본 구현은 보상에 음수를 섞고 분산을 키웠고, judge 파싱 실패 시 보상이 0으로 무너졌습니다.

역할

논문 공개 뒤 후속으로 SFT 데이터 선별, 루브릭 기반 RL 학습·평가를 직접 수행했습니다.

해결

- ✓ 학습 로그에서 불안정한 Reward의 원인이 일괄 채점임을 확인하고 채점 단위를 개별 항목으로 교체 (verl 기반 DAPO-style GRPO, B200 ×4)
- ✓ judge 출력이 깨져 보상이 0이 되는 샘플을 파싱 보강으로 복구해 학습 신호 손실을 차단

성과

HealthBench 14B +6.3, 32B +9.0

관찰·해석

모델이 무엇을 학습할지는 데이터 선별과 보상 설계가 정합니다. 특정 도메인에 맞춘 모델을 학습할 때도 학습이 흔들리면 보상 분포를 먼저 확인하고, 보상함수와 출력 파싱이 학습 목표를 제대로 보상에 옮기고 있는지 점검합니다.