Portfolio

황형순
고려대학교 컴퓨터학과 석사과정
인공지능응용전공

LLM·RAG·Agent 기술을 연구하고 실제 문제에서 검증하는 LLM 연구자입니다.

Research Keywords **LLM · RAG · AI Agent · VLM · Post-training**

5편

논문

- EMNLP 2026 Main 2편
- SCIE 저널 1편
- ACL·IJCAI Workshop 각 1편

1위 ×2

국제 의료 QA 챌린지

- MedHopQA · 리더보드 1위
- ArchEHR-QA · 리더보드 1위

대상

삼성증권 프로그램

- sLLM 투자 정보 검색 서비스 구현

Kaggle Expert

Kaggle · DACON · 기타

- 파킨슨병 예측 · 은메달
- Vesuvius 잉크 검출 · 동메달
- 도배 하자 분류 · 상위 3%
- 유전체 품종 예측 · 7등
- AWS DeepRacer · 7등

Strengths

연구 역량 3가지와 관련 프로젝트

01

Agentic AI 시스템을 설계하고 검증합니다

검색·생성·판단 역할을 나눈 멀티에이전트 프레임워크를 설계하고, 단계별 기여와 판단 편향을 분석해 구조를 개선합니다. 국제 QA 챌린지 2건 1위.

프로젝트

MedHopQA 1위 · ArchEHR-QA 1위
IJCAI·ACL Workshop 공동 1저자

02

생성형 AI 모델을 학습하고 추론 효율을 최적화합니다

SFT 데이터 선별, 루브릭 RL·GRPO 보상 설계로 LLM을 post-training하고, 장황함 분리 증류와 training-free test-time 최적화로 추론 비용 대비 성능을 높입니다.

프로젝트

루브릭 RL(Meerkat2) HealthBench +9.0
FineWeb-Reasoning(GRPO) GSM8K 12.1→43.0
Latent Block(추론 최적화) 벤치마크 5종 성능 개선

03

도메인 특화 LLM의 학습 데이터를 만들고 학습하고 검증합니다

법령 원문·논문·도구 실행 기록에서 학습 QA와 trajectory를 합성해 SFT·RL로 학습하고, 벤치마크 실패 사례와 LLM judge 검수로 데이터를 다시 검증해 모델 성능을 높입니다.

프로젝트

Meerkat2(의료) 법령 QA 검증 · 루브릭 SFT·RL 14B/32B
AI-CoScientist(과학 분석) 3.6만 건 합성 · Qwen3.6-27B SFT
FineWeb-Reasoning(추론) 데이터 선별 · base 모델 GRPO

Papers

논문 5편

01 **EMNLP 2026 Main** 게재 확정 · 2저자 · [PDF]

Meerkat2: Bridging Global Reasoning and Local Knowledge for Efficient Medical AI
한·영 의료 추론 LLM (Qwen3 14B·32B) · 법령 QA 합성·검증, 학습, 벤치마크 3종 평가

---

02 **EMNLP 2026 Main** 게재 확정 · 2저자 · [PDF]

Adaptive Latent Block Insertion via Online Reward Optimization
생성 중 잠재 벡터를 삽입·최적화하는 training-free test-time 추론 최적화

---

03 **Database (Oxford Univ. Press, SCIE)** 게재 확정 · 공동 1저자 · [PDF]

Ensemble Multi-Retrieval Methodologies with Reasoning Model Decision in Multi-Step Biomedical QA
MedHopQA 확장 · 단계별 기여 분석과 판단 모델 자기 편향 완화, 테스트 EM 0.87

---

04 **IJCAI 2025 Workshop · BioCreative IX** 공동 1저자 · [PDF]

MedHopQA Shared Task 1위 · Agentic RAG Framework
Retrieval Agent 3종 후보를 Decision Agent가 종합해 답하는 파이프라인, 테스트 EM 0.84

---

05 **ACL 2025 BioNLP Workshop** 공동 1저자 · [PDF]

ArchEHR-QA Shared Task 리더보드 1위 · Multi-Agent Framework
Medical Expert · Recruiting · Decision Agent가 EHR 근거를 선별·검토·종합, 종합 53.7점

Awards

수상 · 대회 성적

ACL 2025 BioNLP Workshop

ArchEHR-QA 리더보드 1위

EHR 기반 환자 질의응답 QA shared task
공개 리더보드 1위 (공식 수상은 별도 없음)

BioCreative IX

MedHopQA 챌린지 1위

의학 다중 홉 질의응답 QA shared task
EM 0.84로 1위

삼성증권 프로그램

대상

sLLM 기반
투자 정보 검색 서비스 구현

Kaggle Expert

파킨슨병 진행 예측 · 은메달
Vesuvius Challenge 잉크 검출 · 동메달

DACON

도배 하자 유형 분류 · 상위 3%
유전체 품종 예측 · 7등

기타 공모전

AWS DeepRacer Championship 2022 · 7등

직무 Fit

기술 스택

학습	DeepSpeed ZeRO-3 · GRPO · SFT · DPO
검색·서빙	PostgreSQL · Graph DB · Vector DB · FastAPI · Docker
모델	Qwen3 · Llama · Kimi K2.6 · GLM · Gemini/GPT/Claude API
도구	Python · PyTorch · Hugging Face

역량	프로젝트 · 비고
생성형 AI 모델 연구 · RAG · Prompt Engineering	– 국제 QA 챌린지 2건 1위 (MedHopQA · ArchEHR-QA) – LG전자 사내 문서 Graph RAG 구축·벤치마크 평가 – 삼성증권 sLLM 증권 리포트 RAG 서비스, 대상
Agentic AI 기술 연구	– 멀티에이전트 파이프라인으로 국제 챌린지 2건 1위 – AI-CoScientist: Kimi K2.6 tool calling 궤적 수집 · executor SFT
AI 기술을 실제 문제에 적용해 검증	– LG전자 산학: PPT·대시보드 기반 Graph RAG 전 과정 단독 연구·구현 – 기존 운영 시스템 대비 검색 성능 +20%p 이상
딥러닝·머신러닝 이해, 유관 전공·프로젝트	– 고려대 컴퓨터학과 인공지능응용전공 석사과정 – EMNLP 2026 Main 2편 · SCIE 1편 · Kaggle Expert(은·동메달)
도메인 특화 LLM 학습 (SFT·RL)	– Meerkat2 의료 14B·32B 루브릭 SFT·RL, HealthBench +9.0 – AI-CoScientist Qwen3.6-27B SFT – FineWeb base GRPO, GSM8K 12.1→43.0 · LogiQA 14.8→37.2
VLM·Vision·GraphDB·VectorDB	– VLM으로 슬라이드 QA를 생성해 벤치마크 구축 – 4개 색인층 그래프 DB를 RRF로 종합 검색
데이터 파이프라인·품질 검증	– 합성 QA 검증 · 법령 QA LF-Eval 검수 – 추론 데이터 품질 점수대별 검수 · trajectory 필터링

Projects

대표 프로젝트 9건

LLM · RAG · Agent · VLM 축을 오가며 연구했습니다.

01 **MedHopQA 챌린지** 챌린지 · Agentic RAG
의료 multi-hop QA · Agentic RAG로 챌린지 1위, 공식 테스트 EM 0.84

02 **MedHopQA 저널 확장** 저널 · SCIE
단계별 기여 분석과 판단 모델 자기 편향 완화로 EM 0.84 → 0.87

03 **시각 문서 Graph RAG** 산학 · VLM · Graph DB · Graph RAG
평가 기준이 없던 RAG에 벤치마크·DB·검색·평가 체계를 직접 설계·구축, +20%p

04 **Meerkat2 · 루브릭 RL** SFT·RL
의료 추론 LLM 데이터 검증부터 루브릭 보상 RL까지, HealthBench +9.0

05 **ArchEHR-QA** 챌린지 · Multi-Agent
EHR 근거 선별 멀티에이전트, 리더보드 1위 · ACL BioNLP 공동 1저자

06 **Latent Block** 연구 · 모델 최적화
생성 중 잠재 벡터를 최적화하는 training-free 추론 개선 · EMNLP 2026 Main

07 **AI-CoScientist** 연구 · Agent 데이터
Planning 데이터 합성, trajectory 검증·executor SFT, 후속 학습법 검토 중

08 **FineWeb-Reasoning** 연구 · 사전학습 데이터·RL
추론 데이터 채점 검수 · base 모델 GRPO 보상 설계, GSM8K 12.1→43.0

09 **sLLM 투자 정보 검색** sLLM 서비스
팀을 이끌며 DB 구축과 RAG 파이프라인 설계를 맡아 삼성증권 프로그램 대상

Other Projects

경진대회 3건

LLM 이전에 쌓은 데이터 모델링·이미지 분류·강화학습 경험입니다.

Kaggle 파킨슨병 진행 예측

은메달

단백질·펩타이드 통계량·임베딩 특성, 유의 단백질 NPX 가중 보정

DACON 도배 하자 유형 분류

상위 3%

하자 사진을 19가지 유형으로 분류 · 드문 유형은 focal loss와 증강(flip·brightness·CutMix)으로 보강, EfficientNetV2 학습

AWS DeepRacer Championship 2022

7위

자율주행 강화학습 보상함수 설계 · 트랙 이탈과 중앙선에서 크게 벗어나는 주행에 페널티, 직진·코너 구간별 가속·감속 보상

PROJECT 01 · Agentic RAG로 의료 multi-hop QA 챌린지 1위, 공식 테스트 EM 0.84

DMIS Lab at MedHopQA-2025: Ensemble Multi-Retrieval Methodologies with Reasoning Language Model Decision [논문 PDF]

BioCreative IX MedHopQA track (13팀 참가) · IJCAI 2025 BC9 Workshop 논문 · 공동 1저자

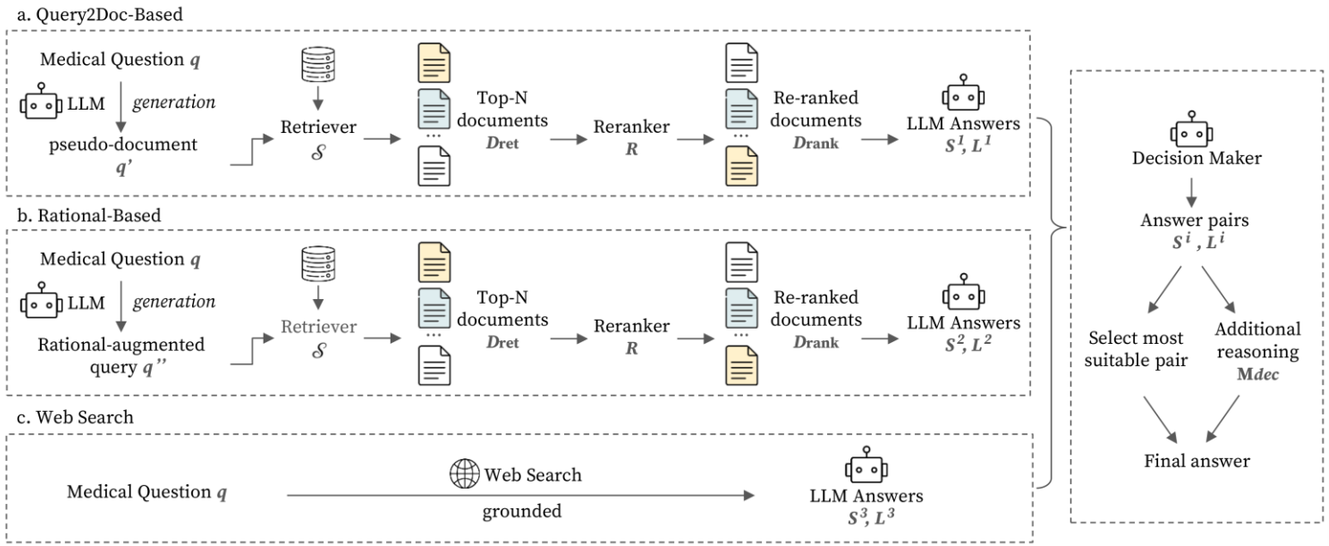


Figure. 세 retrieval 경로가 각각 답 후보(단답·근거)를 만들고, Decision Maker(o3)가 최선의 후보를 고르거나 적합한 후보가 없으면 직접 추론합니다. Query2Doc·Rationale은 위키 sparse 검색 + MedCPT 재정렬, Web Search는 Gemini 2.5 Pro + Google Search를 사용합니다.

1위

BioCreative IX 리더보드

13팀 중 1위 · 테스트 EM 0.84

0.84

테스트 EM · 최종 구성

검색 3경로 + o3 판단 모델
공식 리더보드

문제

MedHopQA는 희귀질환·유전자·화합물을 여러 위키 문서에 걸쳐 추론하는 1만 문항입니다. 검색 없는 GPT-4o는 dev EM 0.60에 그쳤고, 문항마다 맞는 검색 방식이 달랐습니다.

역할

서로 성격이 다른 세 retrieval 방법론의 구축과 비교 실험을 맡았습니다.

해결

- ✓ **Query2Doc:** GPT-4o가 쓴 가상 문서로 위키 sparse 검색 1,000건 → MedCPT 재정렬 200건, GPT-4o가 답 후보 생성
- ✓ **Rationale:** o3가 추론 과정을 담은 질의를 만들고 위키 검색·재정렬 뒤 GPT-4o가 답 후보 생성
- ✓ **Web Search:** Gemini 2.5 Pro + Google Search로 웹 검색 기반 근거 후보 생성
- ✓ **Decision Maker:** o3가 세 후보를 비교해 선택, 적합한 후보가 없으면 직접 답변

성과

공식 테스트 EM 0.84 1위 · IJCAI BC9 Workshop 논문 공동 1저자

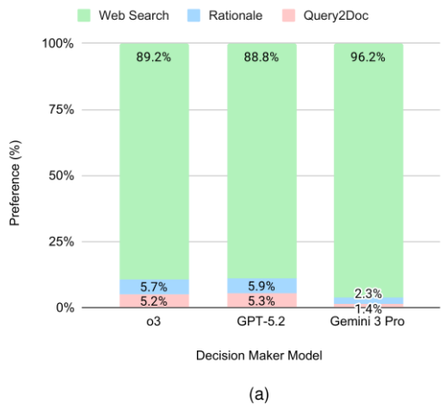
관찰·해석

dev 셋에서 검색 없는 GPT-4o가 EM 0.60, 검색 추가로 0.82, 세 검색 경로 + 판단 모델 프레임워크로 0.87까지 상승했습니다. 같은 구성으로 공식 테스트셋 EM 0.84를 기록해 리더보드 1위에 올랐습니다.

PROJECT 02 · 최신 모델로 단계별 성능을 분해해 자기 편향을 찾아 EM 0.84 → 0.87

Ensemble Multi-Retrieval Methodologies with Reasoning Model Decision in Multi-Step Biomedical QA [논문 PDF]

Database (Oxford Univ. Press, SCIE) 게재 확정 · 공동 1저자 · 챌린지 뒤 Gemini 3 Pro · GPT-5.2 · o3로 재실험



(a)

96.2%

자기 후보 선택 편향

Gemini 3 Pro가 판단까지 맡으면 자신이 만든 Web Search 후보를 최대 96.2% EM 0.84~0.85

0.87

EM · 생성·판단 모델 분리

생성 Gemini 3 Pro + 판단 GPT-5.2. Web 후보 의존이 90.9% → 77.5%로 낮아지며 비교 구성 중 최고

Query2Doc	Rationale	Web Search	Decision Maker	EM Score
GPT-5.2	GPT-5.2	Gemini 3 Pro	o3	0.86
			GPT-5.2	0.86
			Gemini 3 Pro	0.85
Gemini 3 Pro	Gemini 3 Pro	Gemini 3 Pro	GPT-5.2	0.87
			Gemini 3 Pro	0.84

Figure(왼쪽 위). Decision Maker 모델별 세 후보(Web Search·Rationale·Query2Doc) 선택 비율. Table. 생성 모델과 Decision Maker 조합별 테스트 EM(1만 문항). 생성 모델이 같아도 Decision Maker를 GPT-5.2로 바꾸면 0.84 → 0.87.

문제

챌린지 뒤 각 단계에 GPT-5.2·Gemini 3 Pro를 적용했습니다. Gemini 3 Pro는 단독 경로에서 가장 강했지만 판단까지 맡기면 자기 후보에 치우쳐 전체 EM이 0.84~0.85에 머물렀습니다. 문항마다 필요한 검색 방식과 추론 깊이도 달라 세 경로를 모두 돌리는 비용이 컸습니다.

역할

모델 조합·retrieval 단계별 기여 분석, 편향 진단과 구조 개선 실험을 맡았습니다.

해결

- ✓ **생성·판단 분리:** 생성은 Gemini 3 Pro, 판단은 GPT-5.2로 나눠 자기 편향을 줄이고 EM 0.87 달성
- ✓ **Sparse vs Dense:** Qwen3-embedding-8B 밀집 색인과 EM 차이 ±0.02 이내, sparse가 42.5% 빠르고 VRAM 140GB 불필요 → sparse 유지
- ✓ **라우팅 에이전트:** 문항별 reasoning effort와 RAG 방법·순서를 정하는 에이전트를 소규모 실험, 성능 향상 확인 (전체 검증은 API 비용으로 보류)

성과

EM 0.84 → 0.87, 비교 구성 중 최고
Database (Oxford Univ. Press, SCIE) 게재 확정 · 공동 1저자

관찰·해석

개별 모델의 성능과 시스템 전체의 성능은 다릅니다. 결과가 기대에 못 미치면 검색·생성·판단 단계로 나눠 기여를 재고, 판단 모델의 자기 편향을 확인한 뒤 구조를 바꿉니다.

PROJECT 03 · LG전자 산학과제 · 시각 문서 Graph DB 구축과 RAG

시각 문서 Graph DB 구축부터 RAG 벤치마크 평가까지 전 과정 연구·구현

LG전자 산학과제 · 고객 사내 PPT·대시보드 문서 · VLM 색인 · GraphDB · 전 과정 단독 연구·구현

+20%p
Recall·Coverage@10
기존 운영 시스템 대비

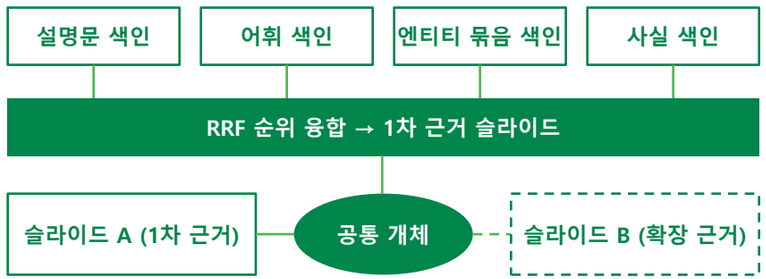
index 4종
색인층 그래프 DB
설명문·어휘·엔티티·사실

관찰·해석

사내 시스템에는 성능을 재는 기준이 없었습니다. 벤치마크와 평가 서버를 먼저 만들어 구조를 바꿀 때마다 효과를 숫자로 확인하고, 사내 운영 시스템도 같은 기준으로 비교했습니다.

근거가 여러 슬라이드에 흩어져 벡터 검색만으로는 부족했습니다. 색인층 4개를 가진 Graph DB에서 개체 관계를 따라 근거를 이어 찾는 Graph RAG로 해결했습니다.

그래프 검색 구조



1차 근거의 개체 관계를 따라 다른 슬라이드까지 근거를 확장

문제

PPT·대시보드 같은 시각 문서를 검색하는 사내 RAG 시스템은 있었지만, 성능을 평가할 기준이 없었습니다. 흩어진 슬라이드에 걸친 다중 근거가 필요한 질문에서 특히 성능이 떨어졌습니다.

역할

벤치마크, 평가 서버, 문서 DB, Graph RAG까지 전 과정을 직접 설계·구현했습니다.

1 추출
VLM으로 개체·관계·설명문 추출

→

2 그래프 DB
PostgreSQL 활용
4개 색인층으로 저장

→

3 Graph RAG
4개 색인 순위를 RRF로 융합, 개체 간 관계를 따라 근거 확장

→

4 평가
검색 품질:
Recall·NDCG·Cov@K
답변 품질:
LLM 심사 5축

해결

- ✓ 공통 요청·응답 규격과 어댑터를 두어 다른 RAG 시스템도 같은 기준으로 비교하고, DB 확장·초기화는 Docker 이미지에 담아 실행 환경을 재현했습니다.
- ✓ 질문과 관련된 정보를 찾은 뒤 개체 간 관계를 따라 다른 문서의 근거까지 탐색하도록 검색을 설계했습니다.

성과

기존 운영 시스템 대비 Recall@10·Coverage@10 모두 20%p 이상 향상

PROJECT 03 · 시각 문서 검색 RAG · 평가 체계 구축과 성과

벤치마크 데이터셋을 자동 생성·검증하고, 이를 실행해 개선을 증명

single-hop / multi-hop 벤치마크 · 평가 서버 · 리더보드

5원칙 생성
문항 5원칙 + 3중 검증
VLM 기반 QA 자동 생성·검증

5축 평가
LLM 심사 답변 평가
정확성·완전성 등

배운점

자동 생성 벤치마크는 문항 품질이 곧 평가의 신뢰도입니다. 생성 규칙과 검증 절차를 먼저 정하고, 평가 결과에서 문제의 원인을 분석해 재설계·실험으로 개선하는 능력을 강화했습니다.

벤치마크 문항 구조

single-hop



한 슬라이드 안에서 답이 나오는 문항

multi-hop



공통 개체로 이어진 여러 슬라이드를 잇는 문항

벤치마크

VLM으로 QA를 자동 생성하되 5원칙과 다중 검증(근거 대조, 마지막은 생성과 다른 모델로 검증)을 거쳐, 한 슬라이드로 답하는 single-hop과 여러 슬라이드를 잇는 multi-hop 벤치마크를 만들었습니다.

평가 지표

- ✓ 검색 단계: Recall@K · NDCG@K · Coverage@K(다중 근거를 얼마나 찾았는지)
- ✓ 답변 단계: LLM 심사 5축(정확성·완전성 등)으로 채점
- ✓ 평가 서버와 리더보드로 확인

검색 설계

설명문·어휘·엔티티 묶음·사실 문장 4개 색인의 순위를 질문마다 RRF로 융합하고, 공통 개체로 이어진 다른 슬라이드까지 근거를 확장했습니다.

성과 · 기존 운영 시스템 대비

+20%p 이상 Recall@10
single-hop 검색 정확도

+20%p 이상 Coverage@10
multi-hop 근거 커버리지

같은 리더보드에서 다른 RAG 시스템도 동일 규격으로 비교할 수 있습니다.

벤치마크 생성·검증 흐름

VLM QA 자동 생성 → 문항 5원칙 필터 → 다중 검증·근거 대조 → 리더보드 등록

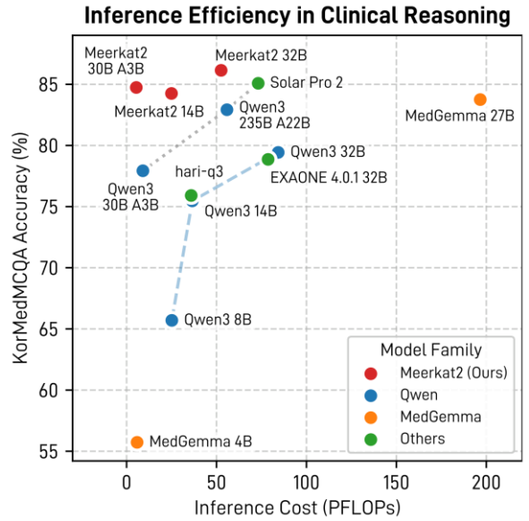
마지막 검증은 생성 모델과 다른 모델이 맡고, 통과한 문항만 벤치마크에 들어가 평가 서버가 같은 기준으로 채점합니다.

PROJECT 04 · 한·영 의료 추론 LLM Meerkat2: Base 모델 대비 의료 질의응답 성능 개선

Meerkat2: Bridging Global Reasoning and Local Knowledge for Efficient Medical AI [논문 PDF]

Qwen3 14B·32B·30B-A3B 기반 학습 · EMNLP 2026 Main 게재 확정 · 2저자

추론 비용 대비 KorMedMCQA 정확도



x축 총 추론 비용(PFLOPs) · y축 KorMedMCQA 정확도(%)

Model	Diagnosis Arena	MediQ	HealthBench Hard	Avg.
Qwen3-14B	8.9	51.0	8.9	22.9
Meerkat2-14B	**12.8**	**60.3**	**9.1**	**27.4**
Qwen3-30B-A3B	12.0	55.5	8.3	25.2
Meerkat2-30B-A3B	**12.4**	**57.2**	**9.3**	**26.3**
Qwen3-32B	13.6	**54.4**	9.1	**25.7**
Meerkat2-32B	**14.6**	51.2	**11.2**	**25.7**

Table. 실제 진료 환경과 유사한 벤치마크 3종

학습 데이터 837K, 세 가지 원칙

01 교사 모델의 풀이 과정 증류

MedQA·KorMedMCQA·MedBooks 문제의 풀이 과정과 답을 교사 모델로 생성하고, 정답을 맞힌 사례를 선별해 학습에 활용

02 법령 지식은 원문에서 합성

한국 의료법 원문에서 문제·해설 QA를 직접 생성. 법령 정확도(LF-Eval) 98.7, 단순 distillation은 79.0

03 장황함 분리 증류(VDD)

긴 teacher 모델 답변에는 "길게 답하라" 지시를 붙여 학습. 정확도 유지하며 생성 토큰 54% 절감

문제

공개 의료 LLM은 영어·미국 진료 기준에 맞춰져 한국 의료법·제도 지식이 약합니다. 또 긴 사고과정을 그대로 증류하면 student 모델이 teacher 모델의 장황한 답변 스타일까지 물려받습니다.

역할

한국 의료법 원문을 기반으로 한 합성 QA를 LF-Eval·수동 검수로 검증하고, HealthBench 등 실전 진료형 벤치마크 3종 평가를 맡았습니다.

해결

- ✓ 추론은 강한 교사 모델에게서 증류하고, 틀리면 안 되는 법령 지식은 원문에서 QA를 직접 만들어 학습 데이터를 분리
- ✓ 장황한 답변은 지시문에 귀속시켜(VDD) 추론력만 물려받고 기본 답변 길이는 짧게 유지

성과

- ✓ **KorMedMCQA에서 14B·32B·30B-A3B 모두 동일 규모 Qwen3 대비 정확도 향상**
- ✓ **실전 진료형 벤치마크 3종 평균 최대 +4.5점** (14B, 22.9→27.4)

관찰·해석

지식의 종류에 따라 데이터 만드는 법이 달라야 합니다. 추론은 교사에게서 배우되, 사실은 원문에서 직접 만들어 검증합니다. 교사 모델은 사고 과정은 잘 보여주지만 한국 법령·제도 같은 사실은 모르거나 틀리게 답하는데, 이를 그대로 증류하면 오류까지 학습하기 때문입니다.

PROJECT 04 · Meerkat2 후속 연구 · 루브릭 보상 RL

Meerkat2 후속 연구: 루브릭 기반 SFT·RL로 HealthBench 9.0점 향상

Meerkat2 14B·32B를 서술형 의료 상담(HealthBench)에 맞게 추가 학습 · 논문 후속 연구

Model	Training	HealthBench	vs. 학습 전
Meerkat2-14B	–	44.9	—
Meerkat2-14B	**Rubric RL**	**51.2**	**+6.3**
Meerkat2-32B	–	46.3	—
Meerkat2-32B	SFT	51.0	+4.7
Meerkat2-32B	**SFT + Rubric RL**	**55.3**	**+9.0**

Table. HealthBench score. 서술형 의료 QA 5,000문항을 의사 작성 루브릭으로 채점. 32B에서 루브릭 RL은 SFT 단독(+4.7) 대비 개선 폭을 약 2배(+9.0)로 확대.

Results

두 모델 모두 학습 전 Meerkat2를 넘음

14B는 44.9→51.2(+6.3), 32B는 46.3→55.3(+9.0)으로 모델 크기와 무관하게 루브릭 RL이 서술형 답변의 질을 끌어올렸습니다.

SFT와 RL이 단계별로 성능을 향상시킴

32B에서 선별한 데이터로 SFT를 하면 46.3→51.0(+4.7), 그 위에 루브릭 RL을 더하면 55.3(+4.3)으로 두 단계가 비슷한 폭으로 기여해 성능을 9.0점 상승시켰습니다.

문제

객관식은 잘 풀어도 서술형 의료 QA(HealthBench 등)는 부족했습니다. 루브릭 점수를 보상으로 RL을 돌리자, 수십 개 항목을 한 번에 채점하는 기본 구현은 보상에 음수를 섞고 분산을 키웠고, judge 파싱 실패 시 보상이 0으로 무너졌습니다.

역할

논문 공개 뒤 후속으로 SFT 데이터 선별, 루브릭 기반 RL 학습·평가를 직접 수행했습니다.

해결

- ✓ 학습 로그에서 불안정한 Reward의 원인이 일괄 채점임을 확인하고 채점 단위를 개별 항목으로 교체 (verl 기반 DAPO-style GRPO, B200 ×4)
- ✓ judge 출력이 깨져 보상이 0이 되는 샘플을 파싱 보강으로 복구해 학습 신호 손실을 차단

성과

HealthBench 14B +6.3, 32B +9.0

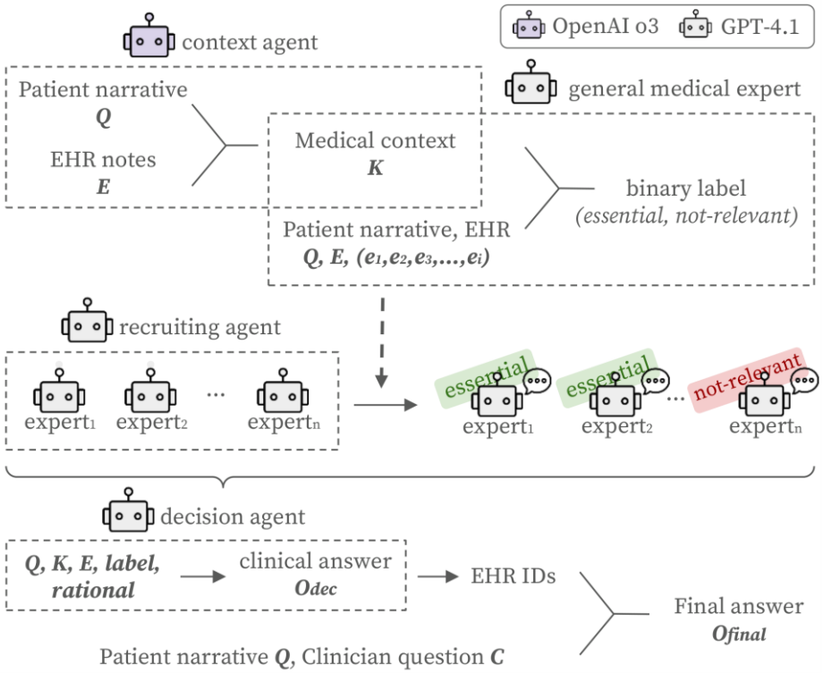
관찰·해석

모델이 무엇을 학습할지는 데이터 선별과 보상 설계가 정합니다. 특정 도메인에 맞춘 모델을 학습할 때도 학습이 흔들리면 보상 분포를 먼저 확인하고, 보상함수와 출력 파싱이 학습 목표를 제대로 보상에 옮기고 있는지 점검합니다.

PROJECT 05 · EHR 노트를 근거로 환자 질문에 답하는 국제 챌린지, 리더보드 1위

DMIS Lab at ArchEHR-QA 2025: Evidence-Grounded Answer Generation for EHR-based QA via a Multi-Agent Framework [논문 PDF]

ACL 2025 BioNLP Workshop shared task · 공식 테스트 종합 53.7 · 공동 1저자



① **맥락 생성 (o3)** 환자 질문·EHR 노트에서 의료 맥락 생성
② **1차 선별** Medical Expert Agent가 문장별 essential / not-relevant 이진 판정
③ **재검토** Recruiting Agent가 구성한 진료과별 Expert Agents가 전문 분야 관점에서 재판정
④ **종합** Decision Agent가 판단을 모아 근거 EHR ID와 최종 답변 생성

리더보드 1위

리더보드 종합 53.7

인용 정확도(F1) 58.6 · 답변 품질 48.8

4단계 에이전트

역할을 나눈 4단계 파이프라인

맥락 생성 → 1차 선별 → 전문가 재검토 → 최종 판단

문제

환자 질문에 EHR 노트를 근거로 답해야 하는데, 어떤 문장이 답변에 필요한 근거인지 가려내는 단계에서 근거를 놓치거나 잘못 인용했습니다.

역할

전체 멀티에이전트 파이프라인 설계와 실험을 맡았습니다.

해결

- ✓ 근거 선별을 문장마다 유효 근거 여부만 묻는 이진 판정으로 바꿔 놓치는 근거를 줄였습니다.
- ✓ 환자 질문에 맞는 의료 맥락을 생성해 판정 에이전트에 넣고, 여러 전문가 에이전트의 검토를 최종 답변에 연결했습니다.

성과

인용 F1 58.6 · 답변 품질 48.8 · 종합 53.7, 리더보드 1위 · ACL 2025 BioNLP Workshop 논문 공동 1저자

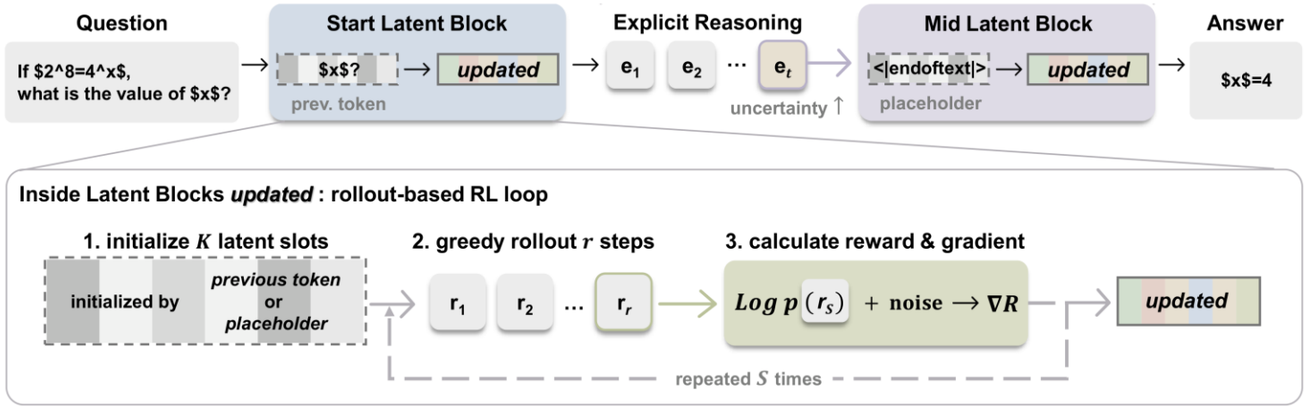
관찰·해석

멀티에이전트 구조의 성능은 역할을 어떻게 나누고 협력 구조를 어떻게 짜는지에서 갈립니다. 맥락 생성, 1차 선별, 전문가 재검토, 최종 결정으로 단계를 나누고 에이전트마다 하나의 역할만 맡기자 놓치는 근거가 눈에 띄게 줄었습니다.

PROJECT 06 · 생성 중 잠재 벡터를 최적화해 추론 성능 개선

Adaptive Latent Block Insertion via Online Reward Optimization [논문 PDF]

EMNLP 2026 Main 게재 확정 · 2저자



불확실성(uncertainty)이 높아지는 지점에 Mid Latent Block을 삽입하고, 짧은 rollout r회의 confidence를 보상으로 latent 벡터를 S회 갱신합니다. 학습 없이 추론 시점에만 동작합니다.

Method	GSM8K	MATH500	AIME2024	AIME2025	ASDivAug	Mean
	B@8 / A@8	B@8 / A@8	B@8 / A@8	B@8 / A@8	B@8 / A@8	B@8 / A@8
Zero-shot CoT	95.91 / 91.76	85.60 / 71.47	16.67 / 10.00	16.67 / 8.75	95.09 / 93.12	61.99 / 55.02
SoftCoT	95.15 / 91.04	**91.60** / 82.17	40.00 / 22.08	26.67 / 18.75	96.92 / 93.99	70.07 / 61.61
LTPO	95.07 / 92.29	91.00 / 83.25	33.33 / 21.67	26.67 / 19.17	96.63 / 83.77	68.54 / 60.03
Ours (w/o mid)	95.83 / 93.26	89.68 / 81.09	36.67 / 22.92	**30.00** / 18.75	96.54 / 93.70	69.74 / 61.94
Ours	**96.91** / 91.51	91.02 / 81.28	**46.67** / 25.00	**30.00** / 19.17	**96.98** / 92.72	**72.32** / 61.94

Table. Qwen3-14B 결과. B@8 = Best-of-8, A@8 = Avg-of-8 정확도(%). SoftCoT는 projection module을 직접 학습해 비교.

문제

LLM은 풀이 중간에 확신이 떨어지는 구간에서 오답으로 흐르지만, 이를 학습으로 고치려면 모델 재훈련이 필요합니다. 추론 시점에만 개입해 성능을 올리는 방법이 필요했습니다.

역할

비교 기법(LTPO·SoftCoT)을 직접 훈련·실험하고 제안 방법과 같은 조건에서 비교하는 작업을 맡았습니다.

해결

- ✓ 제안 방법: 토큰별 불확실성이 이어지는 구간을 감지해 Mid Latent Block을 삽입하고, 짧은 rollout의 confidence를 보상으로 latent 벡터를 문제별로 최적화 (training-free)
- ✓ LTPO 실험: 생성 시작점에서만 latent를 최적화하는 방식과 비교해 중간 삽입의 효과 검증
- ✓ SoftCoT 훈련: 보조 모델의 latent를 LLM에 연결하는 projection module을 Qwen3·Ministral에서 학습해 학습 기반 방법과도 같은 조건에서 비교

성과

벤치마크 5종에서 비교 기법 대비 개선 · EMNLP 2026 Main Accepted

관찰·해석

latent 추론은 사고 과정을 explicit한 텍스트가 아닌 연속 벡터에 담아 토큰 생성 비용을 줄이고, 여기에 test-time 최적화를 더하면 재훈련 없이도 정확도를 훈련 방법론 이상으로 높일 수 있음을 확인했습니다.

PROJECT 07 · AI-CoScientist · 과학 데이터 분석 에이전트

분석 절차를 스스로 계획·실행하는 AI-CoScientist Agent

Planning 데이터 약 3.6만 건 합성 · tool calling trajectory 수집·검증 · executor(Qwen3.6-27B) SFT·평가

Planning + Trajectory

학습 데이터 2종을 직접 구축

Planning 데이터: 논문의 분석 절차를 정답으로 두고 질문→계획→실행 과정을 합성
Trajectory 데이터: Kimi K2.6이 plan에 맞게 tool calling으로 문제를 푸는 과정 전체를 수집·검증

학습 파이프라인 · 4단계 (후속 학습법 검토 중)

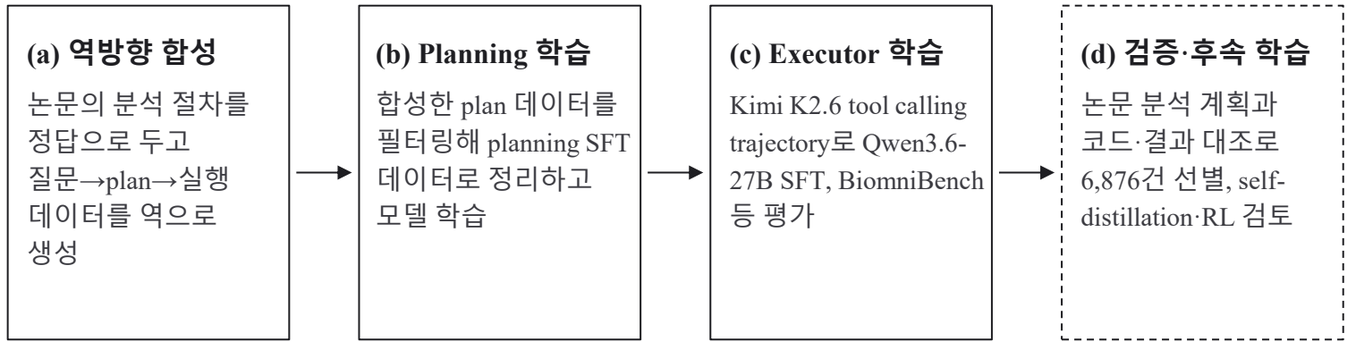


Figure. 학습 데이터 구축 및 학습 파이프라인. 점선 상자는 진행 중인 단계.

문제

연구 에이전트는 사용자 의도에 맞게 분석 계획을 세우고 적절한 툴을 골라 실행해야 하는데, 이를 가르칠 학습 데이터가 없었습니다.

역할

Planning 학습 데이터 구축·필터링, executor SFT와 성능 평가를 맡았습니다.

해결

- ✓ 논문 절차를 정답으로 두고, 질문→결과의 추론·실행 과정을 gpt-5.2로 역방향 합성해 Planning 데이터 3.6만 건 구축
- ✓ Kimi K2.6의 tool calling trajectory로 Qwen3.6-27B를 SFT하고 BiomniBench 등에서 실패 사례 분석
- ✓ GLM-5.2 일관성 검증이 가짜 데이터 분석까지 통과시키는 한계가 있어 논문 분석 계획과 코드·결과를 대조하는 2차 검증 추가

진행

self-distillation·RL(보상 함수 설계) 등 후속 학습법 검토 중
BiomniBench, BixBench 등으로 일반화 평가

관찰·해석

데이터가 없는 영역은 정답이 담긴 문서를 뒤집어 학습 데이터로 바꿀 수 있습니다. 궤적은 최종 결과만 보지 않고 실행하지 않은 도구 호출이나 지어낸 관찰(fabrication) 같은 허위가 없는지로 걸러야 믿을 수 있는 에이전트가 됩니다.

PROJECT 08 · FineWeb-Reasoning · 추론 중심 사전학습 데이터

보상 함수 설계로 base 모델을 SFT 없이 GRPO 학습

추론 품질 채점 프롬프트 검증 · base 모델 GRPO · reward hacking 유형별 감점 보상함수 설계

GSM8K 12.1→43.0
LogiQA 14.8→37.2

SFT 없이 base 모델 RL 성공 · 동급 일반 코퍼스 모델 초과

GSM8K 12.1→43.0, LogiQA 14.8→37.2로 동급 일반 코퍼스 모델을 넘고 SmolLM2 이상
고품질 추론 문서로 사전학습한 자체 base 모델에 cold start(SFT) 없이 GRPO만 적용

학습 파이프라인 · 4단계

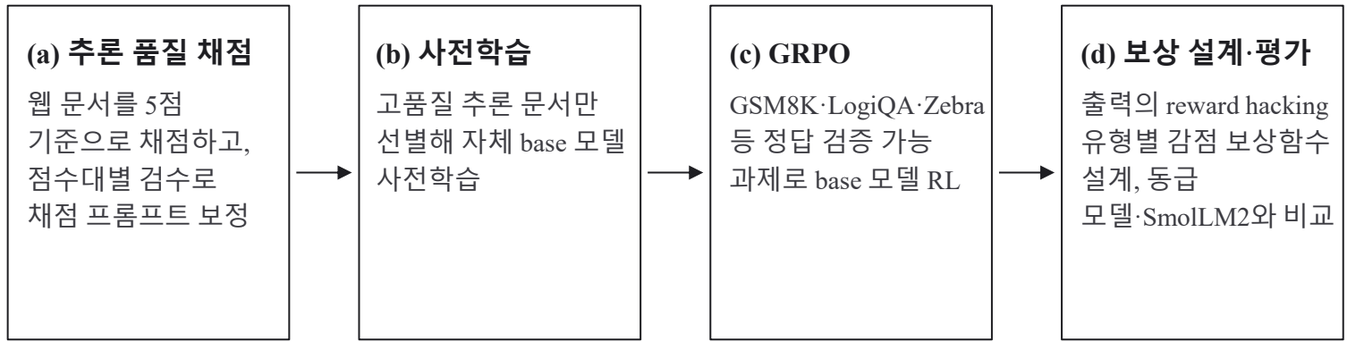


Figure. 추론 데이터 선별부터 base 모델 GRPO까지의 학습 파이프라인.

문제

5점 추론 채점 기준이 실제 품질과 어긋나는 사례가 있었고, 형식·정답만 보는 보상으로 base 모델을 GRPO하면 객관식에서 보상만 오르고 출력이 무너졌습니다.

역할

추론 품질 평가 프롬프트 검증과, 그 데이터로 사전학습한 base 모델의 GRPO를 맡았습니다.

해결

- ✓ 점수대별 문서를 직접 검수해 채점과 실제 추론 품질이 어긋나는 사례를 찾아 추론 품질 평가 프롬프트에 반영
- ✓ 출력을 읽어 선택지 나열, think 비우기, 단서 베끼기 등 편법 유형을 나누고 유형별로 감점하는 보상함수 설계
- ✓ Zebra는 같은 그리드 문항이 학습·평가에 섞이지 않게 재분할
- ✓ cold start(짧은 SFT)보다 보상 설계만으로 푼 쪽이 더 높은 성능

성과

GSM8K 12.1→43.0 (동급 일반 코퍼스 모델 초과)
LogiQA 14.8→37.2 (SmolLM2 이상)

관찰·해석

보상함수는 점수가 아니라 출력을 실제로 읽어야 검증됩니다. 보상만 오르는 학습은 편법을 배우는 reward hacking일 수 있습니다. 실제 출력에서 편법 유형을 찾아 보상에 반영했고, 이 경험이 이후 루브릭 RL에서 보상 분포와 파싱을 점검하는 기준이 됐습니다.

PROJECT 09 · sLLM 기반 투자 정보 검색 서비스

sLLM과 하이브리드 검색으로 만든 투자 정보 검색 서비스

삼성증권 프로그램 대상 · 증권사 리포트를 근거로 답하는 챗봇 · LLaMA2 · 하이브리드 RAG

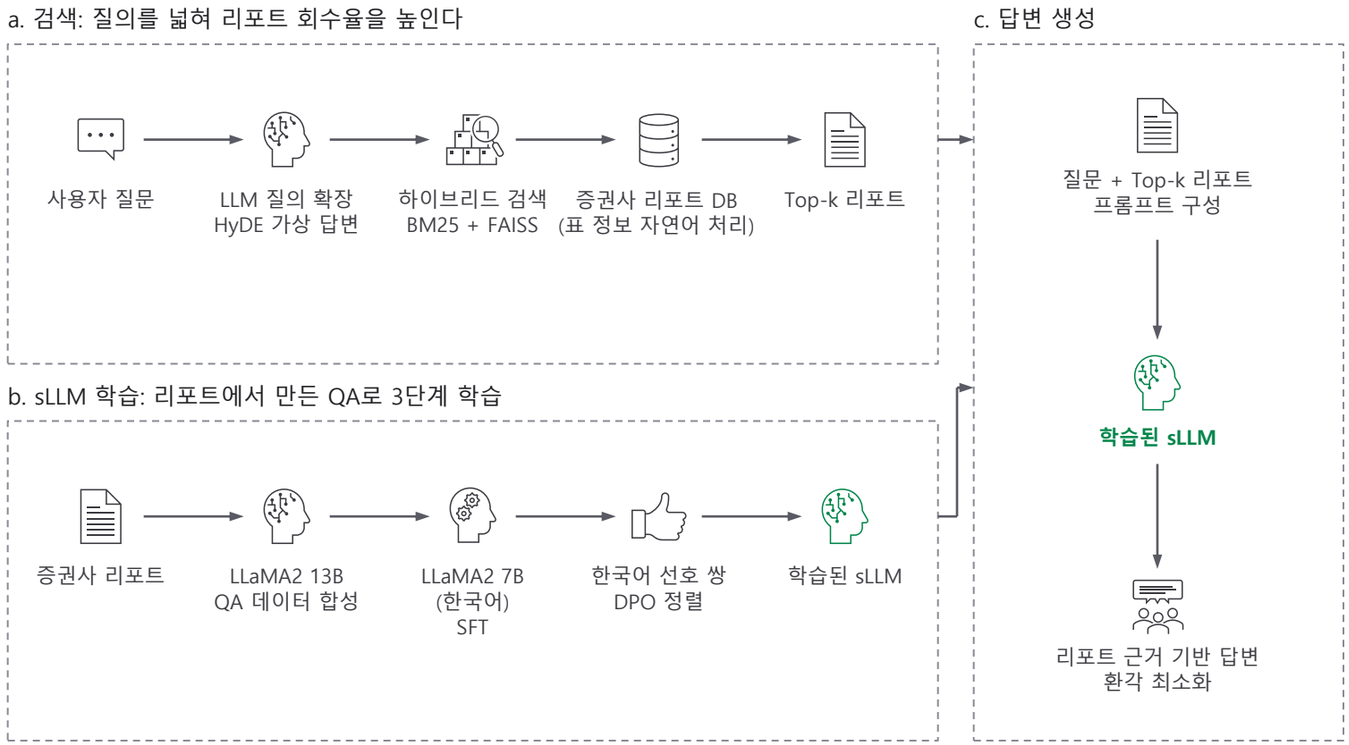


Figure. 투자 정보 검색 서비스 구성. (a) 질의 확장과 하이브리드 검색으로 리포트를 찾고, (b) 리포트에서 합성한 QA로 sLLM을 학습해, (c) 찾아온 리포트를 근거로 답변합니다.

대상

삼성증권 주최

팀 프로젝트 주도

3단계 학습

sLLM 학습

QA 합성 → SFT → DPO

문제

LLaMA2가 공개된 2023년, sLLM은 답변 성능이 낮고 환각이 심했습니다. 팀원들은 NLP를 주력으로 다루지 않아 RAG 기술 검토부터 실험 계획까지 제가 주도했습니다.

역할

과제를 모델의 금융 답변 능력과 근거 검색 두 축으로 나누고, 기술 선택과 적용 계획을 이끌었습니다.

해결

- ✓ LLaMA2 13B로 리포트에서 QA를 합성해 7B 모델을 SFT하고, 한국어 선호도 쌍으로 DPO 정렬
- ✓ BM25와 FAISS를 결합하고, 검색에 잘 잡히지 않는 표에는 예상 질문 텍스트를 붙여 노출
- ✓ LLM 질의 확장과 HyDE로 질문을 리포트 표현에 가깝게 넓혀 회수율을 높임

성과

학습된 생성 모델과 다단계 검색을 결합한 파이프라인으로 대상을 받았습니다. 리포트에 충실한 답변과 낮은 환각 비율이 평가 포인트였습니다.

관찰·해석

팀 프로젝트의 성과는 문제를 어떻게 나누는지에서 갈립니다. 과제를 데이터 추출 및 DB 구축과 근거 검색으로 나누고 기술 선택과 일정을 먼저 제안해, 팀원들이 각자 맡은 부분에 집중하도록 이끌었습니다.

Thank you

황 형 순

Hyeongsoon Hwang